

Missão Prática: A Sabedoria da Floresta

Contexto do Problema

Na missão anterior, lutámos contra o **Overfitting** tentando "podar" uma única Árvore de Decisão. Aprendemos que uma árvore isolada possui alta variância: ela decora os dados de treino e é muito sensível a ruídos.

Nesta missão, em vez de confiarmos o diagnóstico do hospital a um único médico, vamos criar um "conselho médico" utilizando o algoritmo **Random Forest**. O objetivo é provar empiricamente que a combinação de múltiplas árvores reduz o *Gap* entre treino e teste.

A Tarefa

Utilizando o *Google Colab* e o mesmo dataset de Risco de Diabetes, deverá implementar as três configurações abaixo e observar o poder computacional do modelo `RandomForestClassifier`.

1. **A Árvore Solitária (Baseline):** Instancie uma Árvore de Decisão sem limites para relembrar o problema.

Dica: `DecisionTreeClassifier(random_state=42)`

2. **A Pequena Floresta:** Instancie uma Random Forest com apenas 10 árvores.

Dica: `RandomForestClassifier(n_estimators=10, random_state=42)`

3. **A Grande Floresta Paralelizada:** Instancie uma Random Forest com 150 árvores. Utilize o parâmetro `n_jobs=-1` para dizer ao Python para usar todos os núcleos do processador e treinar as árvores em paralelo.

Dica: `RandomForestClassifier(n_estimators=150, n_jobs=-1, random_state=42)`

4. **A Floresta Podada (O Estado da Arte):** Instancie uma Random Forest com 150 árvores, mas agora limite a profundidade máxima de cada árvore a 5 níveis. Este é o modelo que junta o poder da multidão com a sabedoria da poda.

Dica: `RandomForestClassifier(n_estimators=150, max_depth=5, n_jobs=-1, random_state=42)`

Importante: Random State e Dados

Utilize sempre `random_state=42` nos modelos e mantenha a divisão de dados (`test_size=0.3`) do código base. Isto garante o rigor científico da experiência: para comparar algoritmos de forma justa, o conjunto de dados de avaliação tem de ser mantido estritamente constante.

Entregáveis (Relatório)

Preencha a tabela comparativa abaixo. Em seguida, responda às perguntas de análise arquitetural com a sua perspectiva de engenharia.

1. Tabela Comparativa de Métricas

Modelo Configurado	Treino (%)	Teste (%)	Gap (%)
1. Árvore Solitária (DecisionTree)	_____	_____	_____
2. Pequena Floresta (n_estimators=10)	_____	_____	_____
3. Grande Floresta (n_estimators=150)	_____	_____	_____
4. Floresta Podada (n_estimators=150, max_depth=5)	_____	_____	_____

2. Perguntas de Análise (A Decisão do Engenheiro)

A. Ao comparar o **Modelo 3** (Floresta livre) com o **Modelo 4** (Floresta Podada), é provável que repare num detalhe crucial: o Modelo 3 pode apresentar uma acurácia de Teste ligeiramente superior, mas o Modelo 4 possui um *Gap* (diferença entre Treino e Teste) significativamente menor.

Como Engenheiro de Dados num sistema crítico de um hospital, qual dos dois modelos recomendaria colocar em produção? Justifique a sua escolha abordando o compromisso entre "Pico de Acurácia" e "Previsibilidade/Estabilidade" (o clássico *Trade-off* Viés-Variância).

B. (Pensamento de Sistema): O parâmetro `n_jobs=-1` distribui o treino das 150 árvores por todos os núcleos da CPU. Qual é a característica fundamental da arquitetura da Random Forest que permite esta paralelização impecável (ao contrário de algoritmos onde o passo N depende do passo $N - 1$)?

Submeta o relatório preenchido no Google Classroom. Excelente trabalho!